

# Revisão de Probabilidades e Estatística

Afshine AMIDI e Shervine AMIDI

13 de Outubro de 2018

## Introdução a Probabilidade e Combinatória

□ **Espaço amostral** – O conjunto de todos os resultados possíveis é chamado de espaço amostral do experimento e é denotado por  $S$ .

□ **Evento** – Qualquer subconjunto  $E$  do espaço amostral é chamado de evento. Isso é, um evento é um conjunto de possíveis resultados do experimento. Se o resultado do experimento está contido em  $E$ , então é dito que o evento ocorreu.

□ **Axiomas de probabilidade** – Para cada evento  $E$ , denotamos  $P(E)$  a probabilidade do evento  $E$  ocorrer.

$$(1) \quad 0 \leq P(E) \leq 1 \quad (2) \quad P(S) = 1 \quad (3) \quad P\left(\bigcup_{i=1}^n E_i\right) = \sum_{i=1}^n P(E_i)$$

□ **Permutação** – A permutação é um arranjo de  $r$  objetos de um conjunto de  $n$  objetos, em uma determinada ordem. O número desses arranjos é dado por  $P(n, r)$ , definido como:

$$P(n, r) = \frac{n!}{(n-r)!}$$

□ **Combinação** – A combinação de um arranjo de  $r$  objetos de um conjunto de  $n$  objetos, onde a ordem não importa. O número desses arranjos é dado por  $C(n, r)$ , definido como:

$$C(n, r) = \frac{P(n, r)}{r!} = \frac{n!}{r!(n-r)!}$$

*Observação: dado que  $0 \leq r \leq n$ , então temos que  $P(n, r) \geq C(n, r)$ .*

## Probabilidade Condicional

□ **Regra de Bayes** – Para eventos  $A$  e  $B$  tal que  $P(B) > 0$ , temos que:

$$P(A|B) = \frac{P(B|A)P(A)}{P(B)}$$

*Observação: temos que  $P(A \cap B) = P(A)P(B|A) = P(A|B)P(B)$ .*

□ **Partição** – Dado que  $\{A_i, i \in [1, n]\}$  seja tal que para todo  $i$ ,  $A_i \neq \emptyset$ . Dizemos que  $\{A_i\}$  é uma partição se temos:

$$\forall i \neq j, A_i \cap A_j = \emptyset \quad \text{e} \quad \bigcup_{i=1}^n A_i = S$$

*Observação: para qualquer evento  $B$  no espaço amostral temos que  $P(B) = \sum_{i=1}^n P(B|A_i)P(A_i)$ .*

□ **Extensão da regra de Bayes** – Seja  $\{A_i, i \in [1, n]\}$  uma partição do espaço amostral. Temos que:

$$P(A_k|B) = \frac{P(B|A_k)P(A_k)}{\sum_{i=1}^n P(B|A_i)P(A_i)}$$

□ **Independência** – Dois eventos  $A$  e  $B$  são independentes se e apenas se tivermos:

$$P(A \cap B) = P(A)P(B)$$

## Variável aleatória

□ **Variável aleatória** – Uma variável aleatória, normalmente denominada  $X$ , é uma função que mapeia todo elemento em um espaço amostral para uma linha verdadeira.

□ **Função de distribuição cumulativa (CDF)** – A função de distribuição cumulativa  $F$ , que é monotonicamente não decrescente e é tal que

$$\lim_{x \rightarrow -\infty} F(x) = 0 \quad \text{e} \quad \lim_{x \rightarrow +\infty} F(x) = 1$$

é definida como:

$$F(x) = P(X \leq x)$$

*Lembrete: temos que  $P(a < X \leq b) = F(b) - F(a)$ .*

□ **Função densidade de probabilidade (PDF)** – A função densidade de probabilidade  $f$  é a probabilidade de que  $X$  assuma valores entre duas realizações adjacentes da variável aleatória.

□ **Relações envolvendo a PDF e a CDF** – Aqui estão as propriedades mais importantes que se deve conhecer dos casos discretos (D) e contínuos (C).

Caso	CDF $F$	PDF $f$	Propriedades da PDF
(D)	$F(x) = \sum_{x_i \leq x} P(X = x_i)$	$f(x_j) = P(X = x_j)$	$0 \leq f(x_j) \leq 1$ e $\sum_j f(x_j) = 1$
(C)	$F(x) = \int_{-\infty}^x f(y)dy$	$f(x) = \frac{dF}{dx}$	$f(x) \geq 0$ e $\int_{-\infty}^{+\infty} f(x)dx = 1$

□ **Variância** – A variância de uma variável aleatória, normalmente denominada  $\text{Var}(X)$  ou  $\sigma^2$ , é a medida do espalhamento da sua função de distribuição. Ela é determinada por:

$$\text{Var}(X) = E[(X - E[X])^2] = E[X^2] - E[X]^2$$

□ **Desvio padrão** – O desvio padrão de uma variável aleatória, normalmente denominado  $\sigma$ , é a medida do espalhamento da sua função de distribuição que é compatível com a unidade da variável aleatória. Ele é determinado por:

$$\sigma = \sqrt{\text{Var}(X)}$$

□ **Expectativas e Momentos da Distribuição** – Aqui estão as expressões do valor esperado  $E[X]$ , do valor esperado generalizado  $E[g(X)]$ , do  $k$ -ésimo momento  $E[X^k]$  e função característica  $\psi(\omega)$  para os casos discretos e contínuos:

Caso	$E[X]$	$E[g(X)]$	$E[X^k]$	$\psi(\omega)$
(D)	$\sum_{i=1}^n x_i f(x_i)$	$\sum_{i=1}^n g(x_i) f(x_i)$	$\sum_{i=1}^n x_i^k f(x_i)$	$\sum_{i=1}^n f(x_i) e^{i\omega x_i}$
(C)	$\int_{-\infty}^{+\infty} x f(x) dx$	$\int_{-\infty}^{+\infty} g(x) f(x) dx$	$\int_{-\infty}^{+\infty} x^k f(x) dx$	$\int_{-\infty}^{+\infty} f(x) e^{i\omega x} dx$

Remarque: on a  $e^{i\omega x} = \cos(\omega x) + i \sin(\omega x)$ .

□ **Transformação das variáveis aleatórias** – Sejam as variáveis  $X$  e  $Y$  ligadas por alguma função. Ao denotador  $f_X$  e  $f_Y$  para as funções de distribuição de  $X$  e de  $Y$  respectivamente, temos que:

$$f_Y(y) = f_X(x) \left| \frac{dx}{dy} \right|$$

□ **Regra integral de Leibniz** – Seja  $g$  uma função de  $x$  e possivelmente de  $c$ , e  $a, b$  fronteiras que podem depender de  $c$ . Temos que:

$$\frac{\partial}{\partial c} \left( \int_a^b g(x) dx \right) = \frac{\partial b}{\partial c} \cdot g(b) - \frac{\partial a}{\partial c} \cdot g(a) + \int_a^b \frac{\partial g}{\partial c}(x) dx$$

□ **Desigualdade de Chebyshev** – Seja  $X$  uma variável aleatória com valor esperado  $\mu$ . Para  $k, \sigma > 0$ , temos a seguinte desigualdade:

$$P(|X - \mu| \geq k\sigma) \leq \frac{1}{k^2}$$

## Variáveis aleatórias distribuídas conjuntamente

□ **Densidade condicional** – A densidade condicional de  $X$  com respeito a  $Y$ , normalmente denotada como  $f_{X|Y}$ , é definida como:

$$f_{X|Y}(x) = \frac{f_{XY}(x, y)}{f_Y(y)}$$

□ **Independência** – Duas variáveis aleatórias  $X$  e  $Y$  são ditas independentes se:

$$f_{XY}(x, y) = f_X(x) f_Y(y)$$

□ **Densidade marginal e distribuição cumulativa** – A partir da função de probabilidade de densidade conjunta  $f_{XY}$ , temos que:

Caso	Densidade marginal	Função cumulativa
(D)	$f_X(x_i) = \sum_j f_{XY}(x_i, y_j)$	$F_{XY}(x, y) = \sum_{x_i \leq x} \sum_{y_j \leq y} f_{XY}(x_i, y_j)$
(C)	$f_X(x) = \int_{-\infty}^{+\infty} f_{XY}(x, y) dy$	$F_{XY}(x, y) = \int_{-\infty}^x \int_{-\infty}^y f_{XY}(x', y') dx' dy'$

□ **Coveriância** – Definimos covariância de duas variáveis aleatórias  $X$  e  $Y$ , que chamamos de  $\sigma_{XY}^2$  ou mais comumente de  $\text{Cov}(X, Y)$ , como:

$$\text{Cov}(X, Y) \triangleq \sigma_{XY}^2 = E[(X - \mu_X)(Y - \mu_Y)] = E[XY] - \mu_X \mu_Y$$

□ **Correlação** – Dado que  $\sigma_X, \sigma_Y$  são os desvios padrão de  $X$  e  $Y$ , definimos a correlação entre as variáveis aleatórias  $X$  e  $Y$ , denominada  $\rho_{XY}$ , como:

$$\rho_{XY} = \frac{\sigma_{XY}^2}{\sigma_X \sigma_Y}$$

Observação 1: é definido que para qualquer variáveis aleatórias  $X, Y$  temos que  $\rho_{XY} \in [-1, 1]$ .  
Observação 2: Se  $X$  e  $Y$  são independentes, então  $\rho_{XY} = 0$ .

□ **Distribuições principais** – Aqui estão as principais distribuições que não devem ser esquecidas:

Tipo	Distribuição	PDF	$\psi(\omega)$	$E[X]$	$\text{Var}(X)$
(D)	$X \sim \mathcal{B}(n, p)$ Binomial	$P(X = x) = \binom{n}{x} p^x q^{n-x}$ $x \in \llbracket 0, n \rrbracket$	$(pe^{i\omega} + q)^n$	$np$	$npq$
	$X \sim \text{Po}(\mu)$ Poisson	$P(X = x) = \frac{\mu^x}{x!} e^{-\mu}$ $x \in \mathbb{N}$	$e^{\mu(e^{i\omega} - 1)}$	$\mu$	$\mu$
(C)	$X \sim \mathcal{U}(a, b)$ Uniform	$f(x) = \frac{1}{b-a}$ $x \in [a, b]$	$\frac{e^{i\omega b} - e^{i\omega a}}{(b-a)i\omega}$	$\frac{a+b}{2}$	$\frac{(b-a)^2}{12}$
	$X \sim \mathcal{N}(\mu, \sigma)$ Gaussian	$f(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2}$ $x \in \mathbb{R}$	$e^{i\omega\mu - \frac{1}{2}\omega^2\sigma^2}$	$\mu$	$\sigma^2$
	$X \sim \text{Exp}(\lambda)$ Exponential	$f(x) = \lambda e^{-\lambda x}$ $x \in \mathbb{R}_+$	$\frac{1}{1 - \frac{i\omega}{\lambda}}$	$\frac{1}{\lambda}$	$\frac{1}{\lambda^2}$

## Estimativa de parâmetro

□ **Amostra aleatória** – Uma amostra aleatória é uma coleção de  $n$  variáveis aleatórias  $X_1, \dots, X_n$  que são independentes e igualmente distribuídas com  $X$ .

□ **Estimador** – Um estimador é uma função dos dados que é usada para inferir o valor de um parâmetro desconhecido em um modelo estatístico.

□ **Viés** – O viés de um estimador  $\hat{\theta}$  é definido como a diferença entre o valor esperado da distribuição de  $\hat{\theta}$  e o seu real valor, i.e.:

$$\text{Bias}(\hat{\theta}) = E[\hat{\theta}] - \theta$$

*Observação: um estimador é chamado de imparcial (unbiased) quando  $E[\hat{\theta}] = \theta$ .*

□ **Média da amostra** – A média da amostra de uma amostra aleatória é usada para estimar a verdadeira média  $\mu$  de uma distribuição, e é denominada  $\bar{X}$  e é definida como:

*Observação: a média da amostra é imparcial, i.e  $E[\bar{X}] = \mu$ .*

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$

□ **Amostra da variância** – A amostra da variância de uma amostra aleatória é usada para estimar a verdadeira variância  $\sigma^2$  da distribuição, e é normalmente denominada  $s^2$  ou  $\hat{\sigma}^2$  e definida por:

*Observação: a variância da amostra é imparcial, i.e  $E[s^2] = \sigma^2$ .*

$$s^2 = \hat{\sigma}^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

□ **Teorema do Limite Central** – Dado que temos uma amostra aleatória  $X_1, \dots, X_n$  seguindo uma determinada distribuição com a média  $\mu$  e a variância  $\sigma^2$ , temos que:

$$\bar{X} \underset{n \rightarrow +\infty}{\sim} \mathcal{N}\left(\mu, \frac{\sigma}{\sqrt{n}}\right)$$